

NUM8

Łukasz Kowalik

1 Polecenie

Zaproponuj wielomian uogólniony w postaci

$$F(x) = \sum_{j=1}^m a_j \phi_j(x),$$

gdzie ilość parametrów $m \geq 3$, a $\phi_j(x)$ są pewnymi funkcjami. Zdefiniuj siatkę punktów x_i oraz (dla pewnego ustalonego zestawu parametrów a_j) wygeneruj dane w postaci $\{(x_i, y_i)\}$, gdzie $i = 1, \dots, n$, a $y_i = F(x_i) + \delta y_i$. Zaburzenia δy_i należy losować z rozkładu normalnego z odchyleniem standardowym σ .

- (a) Znajdź wartości współczynników a_j , dla których funkcja $F(x)$ najlepiej opisuje zaburzone dane w sensie metody najmniejszych kwadratów. Wynik przedstaw graficznie dla kilku wyborów wielkości siatki, n , oraz odchylenia standardowego, σ .
- (b) Przeanalizuj różnice pomiędzy wcześniej ustalonymi współczynnikami, a ich wartościami uzyskanymi w procedurze aproksymacji przeprowadzonej dla zaburzonych danych.

2 Przedstawienie problemu

W ramach zadania wybrano kilka interesujących funkcji bazowych $\phi_j(x)$, które zostały użyte w wielomianie uogólnionym. Funkcje te stanowią podstawę modelu i mają kluczowe znaczenie dla jakości uzyskiwanych wyników aproksymacji.

Następnie wygenerowano siatkę punktów x_i ($i = 1, \dots, n$), gdzie n jest parametrem definiowanym przez użytkownika. Siatka ta umożliwia określenie wartości funkcji w zadanych punktach, zarówno dla modelu idealnego, jak i zaburzonego. Przyjęto również ustalone wartości współczynników a_j , które definiują rzeczywisty kształt funkcji $F(x)$. Te współczynniki będą później wykorzystywane jako punkt odniesienia do oceny jakości uzyskanej aproksymacji.

Idealne wartości funkcji $F(x)$ obliczono na podstawie zależności:

$$F(x_i) = \sum_{j=1}^m a_j \phi_j(x_i),$$

a następnie dodano do nich losowe zaburzenia δy_i , generowane zgodnie z rozkładem normalnym o średniej 0 i odchyleniu standardowym σ . Otrzymane wartości y_i opisano jako:

$$y_i = F(x_i) + \delta y_i.$$

Celem zadania jest odzyskanie współczynników a_j na podstawie wygenerowanych par (x_i, y_i) . W tym celu zastosowano metodę najmniejszych kwadratów, która minimalizuje funkcję błędu:

$$E(a_1, \dots, a_m) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^m a_j \phi_j(x_i) \right)^2.$$

3 Metoda najmniejszych kwadratów i dekompozycja SVD

3.1 Metoda najmniejszych kwadratów

Metoda najmniejszych kwadratów (ang. *Least Squares Method*) jest klasycznym podejściem do dopasowania modelu do danych w taki sposób, aby minimalizować sumę kwadratów błędów. W przypadku zadania aproksymacji, chcemy znaleźć współczynniki a_j funkcji $F(x)$, które minimalizują funkcję błędu:

$$E(a_1, \dots, a_m) = \sum_{i=1}^n \left(y_i - \sum_{j=1}^m a_j \phi_j(x_i) \right)^2.$$

Aby rozwiązać to zadanie, można zapisać problem w formie macierzowej. Niech:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_m(x_1) \\ \phi_1(x_2) & \phi_2(x_2) & \cdots & \phi_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_m(x_n) \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix}.$$

Wówczas problem minimalizacji można zapisać jako:

$$E(\mathbf{a}) = \|\mathbf{A}\mathbf{a} - \mathbf{y}\|^2.$$

Optymalne współczynniki \mathbf{a} spełniają układ równań normalnych:

$$\mathbf{A}^T \mathbf{A} \mathbf{a} = \mathbf{A}^T \mathbf{y}.$$

3.2 Dekompozycja SVD

W praktyce, szczególnie gdy macierz \mathbf{A} jest źle uwarunkowana lub niekwadratowa, układ równań normalnych może prowadzić do błędnych wyników. W

takich przypadkach stosuje się dekompozycję SVD (ang. *Singular Value Decomposition*), która zapewnia bardziej stabilne rozwiązanie.

Dekompozycja SVD rozkłada macierz \mathbf{A} na iloczyn trzech macierzy:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

gdzie:

- \mathbf{U} jest macierza ortogonalna ($\mathbf{U}^T\mathbf{U} = \mathbf{I}$),
- $\mathbf{\Sigma}$ jest macierza diagonalna zawierająca wartości singularne σ_i ,
- \mathbf{V} jest macierza ortogonalna ($\mathbf{V}^T\mathbf{V} = \mathbf{I}$).

Rozwiązanie problemu najmniejszych kwadratów za pomocą SVD wyraża się jako:

$$\mathbf{a} = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^T\mathbf{y},$$

gdzie $\mathbf{\Sigma}^+$ jest macierza pseudoodwrotna do $\mathbf{\Sigma}$, otrzymywana poprzez odwrócenie jej niezerowych elementów diagonalnych.

3.3 Zalety zastosowania SVD

Zastosowanie dekompozycji SVD ma następujące zalety:

- Jest stabilne numerycznie, szczególnie w przypadku źle uwarunkowanych macierzy.
- Umożliwia łatwą identyfikację i eliminację najmniejszych wartości singularnych, co pomaga w redukcji efektów błędów zaokrągleń i szumów w danych.
- Daje rozwiązanie nawet w przypadku układów równań nadokreślonych (gdy $n > m$) lub niedookreślonych (gdy $n < m$).

Podsumowując, metoda najmniejszych kwadratów w połączeniu z dekompozycją SVD jest skutecznym narzędziem do aproksymacji danych w obecności szumów, zapewniając wysoką dokładność i stabilność obliczeń.

4 Wybrany wielomian uogólniony

W zadaniu zdecydowano się na użycie wielomianu uogólnionego z $m = 6$ parametrami. Funkcje bazowe $\phi_j(x)$ zostały dobrane w taki sposób, aby zachować różnorodność i złożoność zachowania funkcji w przedziale $x \in (-1, 1)$. Wybrane funkcje bazowe to:

$$\begin{aligned}
\phi_1(x) &= \sin(x \cdot e^x), \\
\phi_2(x) &= \cos(\log(x^2) \cdot \tanh(x)), \\
\phi_3(x) &= \exp(x^2 \cdot \sin(x^2)), \\
\phi_4(x) &= \sin(\cos(e^x)), \\
\phi_5(x) &= \cos\left(\frac{1}{1+|x|} \cdot e^x\right).
\end{aligned}$$

Współczynniki a_j zostały ustalone na następujące wartości:

$$a_1 = -0.5, \quad a_2 = 1.0, \quad a_3 = -0.5, \quad a_4 = 1.5, \quad a_5 = -0.5, \quad a_6 = -2.5.$$

Taki dobór współczynników został dokonany z zamiarem uzyskania ciekawego zachowania funkcji $F(x)$ w zadanym przedziale. Wartości te pozwalają na generowanie danych charakteryzujących się dużą zmiennością i złożonymi zależnościami między wartościami x_i i y_i , co sprzyja dokładnemu sprawdzeniu skuteczności metody aproksymacji.

Analiza funkcji bazowych

Wybrane funkcje bazowe są nieliniowe i wprowadzają różne cechy do modelu:

- $\phi_1(x) = \sin(x \cdot e^x)$ – generuje oscylacje, których amplituda rośnie wykładniczo.
- $\phi_2(x) = \cos(\log(x^2) \cdot \tanh(x))$ – wprowadza funkcje logarytmiczną w połączeniu z hiperboliczną.
- $\phi_3(x) = \exp(x^2 \cdot \sin(x^2))$ – zwiększa nieliniowość, wprowadzając funkcje wykładniczą skomponowaną z sinusoidą.
- $\phi_4(x) = \sin(\cos(e^x))$ – łączy funkcje trygonometryczne i wykładnicze.
- $\phi_5(x) = \cos\left(\frac{1}{1+|x|} \cdot e^x\right)$ – wprowadza funkcje wymierną, wzmacniając różnorodność.

Przyjęte funkcje i współczynniki mają na celu stworzenie ciekawego i wymagającego przypadku testowego, umożliwiającego dokładne sprawdzenie skuteczności metody najmniejszych kwadratów.

5 Wyniki dla różnych poziomów zaburzeń i liczby punktów

Wyniki aproksymacji zostały przeanalizowane dla różnych wartości odchylenia standardowego zaburzeń (σ) oraz liczby punktów (N). Poniżej przedstawiono wyznaczone współczynniki aproksymacji oraz wizualizacje funkcji.

5.1 Zaburzenie $\sigma = 0.1$

- Liczba punktów $N = 10$:

$$a = \{-0.587054, 1.02244, -0.482905, 1.4313, -0.618955, -2.39197\}.$$

- Liczba punktów $N = 25$:

$$a = \{-0.524002, 0.986735, -0.503234, 1.41216, -0.573481, -2.30794\}.$$

- Liczba punktów $N = 70$:

$$a = \{-0.419742, 1.21583, -0.565099, 1.43645, -0.376014, -2.67486\}.$$

- Liczba punktów $N = 100$:

$$a = \{-0.502208, 0.75287, -0.44646, 1.39498, -0.503609, -2.08698\}.$$

5.2 Zaburzenie $\sigma = 0.5$

- Liczba punktów $N = 10$:

$$a = \{0.171659, 4.36458, -1.35513, 4.16532, 0.0422072, -10.9065\}.$$

- Liczba punktów $N = 25$:

$$a = \{0.304039, 1.4799, -0.546012, 3.10255, 0.527213, -6.82663\}.$$

- Liczba punktów $N = 70$:

$$a = \{-0.564114, 0.507845, -0.365722, 1.37339, -0.611113, -1.74082\}.$$

- Liczba punktów $N = 100$:

$$a = \{-1.32073, 0.636297, -0.518278, 0.812597, -1.23661, -0.061968\}.$$

5.3 Zaburzenie $\sigma = 1.5$

- Liczba punktów $N = 10$:

$$a = \{0.515271, 0.0198563, 0.685153, 0.663381, 1.8435, -4.97215\}.$$

- Liczba punktów $N = 25$:

$$a = \{-2.11554, -1.55792, 0.00921909, 0.108171, -2.39021, 3.8261\}.$$

- Liczba punktów $N = 70$:


$$a = \{-3.1152, 4.56663, -2.18418, 1.46649, -2.95888, -1.5162\}.$$

- Liczba punktów $N = 100$:


$$a = \{-1.62989, -0.617211, -0.801978, -1.74618, -1.79915, 7.46054\}.$$

5.4 Wizualizacja wyników



Dla wybranych parametrów σ i N przygotowano wykresy aproksymowanych funkcji:




Wykres funkcji $F(x)$ dla $\sigma = 0.1$ i $N = 10$.




Wykres funkcji $F(x)$ dla $\sigma = 0.1$ i $N = 25$.


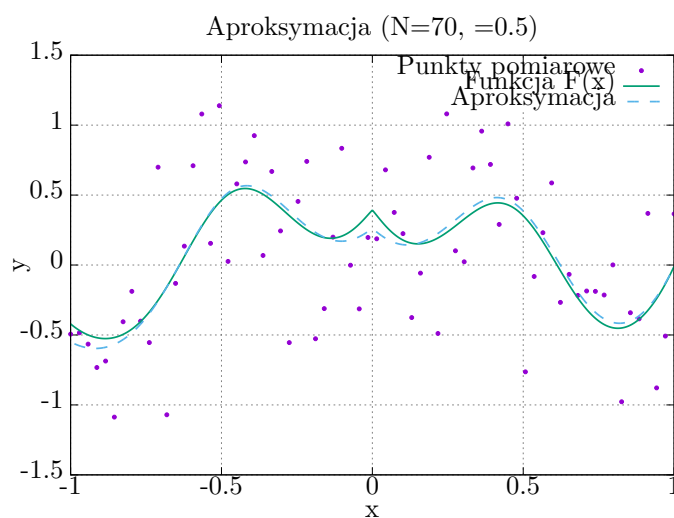


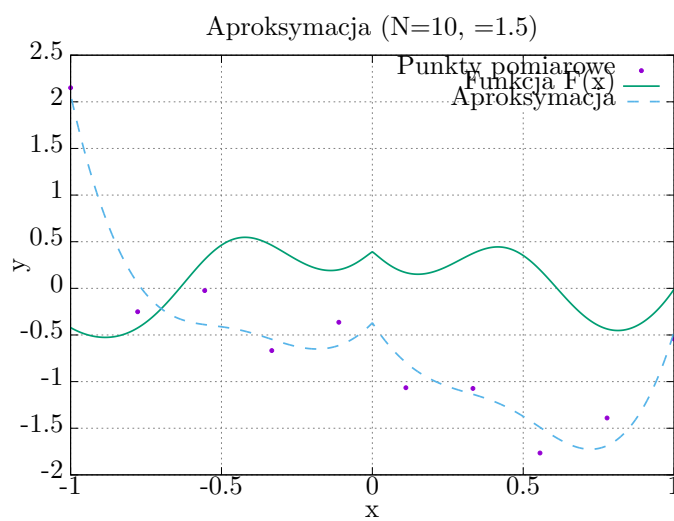


Wykres funkcji $F(x)$ dla $\sigma = 0.5$ i $N = 10$.




Wykres funkcji $F(x)$ dla $\sigma = 0.5$ i $N = 25$.







Wykres funkcji $F(x)$ dla $\sigma = 1.5$ i $N = 10$.



Wykres funkcji $F(x)$ dla $\sigma = 1.5$ i $N = 25$.



Wykres funkcji $F(x)$ dla $\sigma = 1.5$ i $N = 70$.



Wykres funkcji $F(x)$ dla $\sigma = 1.5$ i $N = 100$.

6 Dyskusja

Wyniki aproksymacji funkcji $F(x)$ w obecności różnych poziomów zaburzeń (σ) oraz liczby punktów (N) pozwalają na wyciągnięcie kilku istotnych wniosków dotyczących stabilności i dokładności metody najmniejszych kwadratów.

6.1 Wpływ liczby punktów (N)

Wraz ze wzrostem liczby punktów (N), wyniki aproksymacji stają się bardziej stabilne i dokładniejsze. Dla mniejszych wartości N , takich jak $N = 10$, współczynniki a_j znacząco odbiegają od wartości oryginalnych. Wynika to z ograniczonej ilości informacji dostarczanej przez dane, co prowadzi do niestabilności w procesie aproksymacji. Z kolei dla większych wartości N , takich jak $N = 70$ lub $N = 100$, wyznaczone współczynniki są bliższe oryginalnym wartościom, nawet przy wyższym poziomie zaburzeń ($\sigma = 0.5$).

6.2 Wpływ poziomu zaburzeń (σ)

Zwiększenie poziomu zaburzeń (σ) prowadzi do większych odchyłeń współczynników aproksymacji od ich rzeczywistych wartości. Dla $\sigma = 0.1$, uzyskane współczynniki są stosunkowo bliskie pierwotnym wartościom nawet przy niewielkiej liczbie punktów N . Natomiast dla $\sigma = 1.5$, nawet przy $N = 100$, aproksymacja jest znacząco zaburzona, co wskazuje na ograniczenia metody najmniejszych kwadratów w obecności dużego szumu.

6.3 Porównanie wyników

Analizując wyniki dla różnych kombinacji N i σ , można zauważyć, że metoda najmniejszych kwadratów działa najlepiej przy umiarkowanym poziomie szumu ($\sigma \leq 0.5$) oraz odpowiednio dużej liczbie punktów ($N \geq 70$). W takich przypadkach uzyskane współczynniki a_j są zbliżone do rzeczywistych wartości, a wykresy funkcji dobrze odwzorowują oryginalną funkcję $F(x)$.

Z kolei przy dużych zaburzeniach ($\sigma = 1.5$) metoda staje się mniej efektywna, co jest szczególnie widoczne dla mniejszych N . W takich sytuacjach konieczne może być zastosowanie bardziej zaawansowanych metod aproksymacji, takich jak regularizacja (np. metoda grzbietowa) lub metody odpornościowe (ang. *robust methods*), które lepiej radzą sobie z szumem.

7 Wnioski

Przeprowadzona analiza pokazuje, że metoda najmniejszych kwadratów jest skuteczna przy niskim poziomie szumu i wystarczająco dużej liczbie punktów. Jednak w przypadku większych zaburzeń konieczne jest rozważenie bardziej zaawansowanych metod, które zapewnia lepszą odporność na szum i większą stabilność wyników.