

# NUM8

Łukasz Kowalik

## 1 Polecenie

Zaproponuj wielomian uogólniony w postaci

$$F(x) = \sum_{j=1}^m a_j \phi_j(x),$$

gdzie ilość parametrów  $m \geq 3$ , a  $\phi_j(x)$  są pewnymi funkcjami. Zdefiniuj siatkę punktów  $x_i$  oraz (dla pewnego ustalonego zestawu parametrów  $a_j$ ) wygeneruj dane w postaci  $\{(x_i, y_i)\}$ , gdzie  $i = 1, \dots, n$ , a  $y_i = F(x_i) + \delta y_i$ . Zaburzenia  $\delta y_i$  należy losować z rozkładu normalnego z odchyleniem standardowym  $\sigma$ .

- (a) Znajdź wartości współczynników  $a_j$ , dla których funkcja  $F(x)$  najlepiej opisuje zaburzone dane w sensie metody najmniejszych kwadratów. Rezultat przedstaw graficznie dla kilku wyborów wielkości siatki,  $n$ , oraz odchylenia standardowego,  $\sigma$ .
- (b) Przeanalizuj różnice pomiędzy wcześniej ustalonymi współczynnikami, a ich wartościami uzyskanymi w procedurze aproksymacji przeprowadzonej dla zaburzonych danych.

**UWAGA:** Rozwiązując to zadanie nie można korzystać z procedur bibliotecznych służących do aproksymacji. Poza tym, użycie procedur z zakresu algebry liniowej jest dozwolone.

## 2 Przedstawienie problemu

W ramach zadania wybrano kilka interesujących funkcji bazowych  $\phi_j(x)$ , które zostały użyte w wielomianie uogólnionym. Funkcje te stanowią podstawę modelu i mają kluczowe znaczenie dla jakości uzyskiwanych wyników aproksymacji.

Następnie wygenerowano siatkę punktów  $x_i$  ( $i = 1, \dots, n$ ), gdzie  $n$  jest parametrem definiowanym przez użytkownika. Siatka ta umożliwia określenie wartości funkcji w zadanych punktach, zarówno dla modelu idealnego, jak i zaburzonego. Przyjęto również ustalone wartości współczynników  $a_j$ , które definiują rzeczywisty kształt funkcji  $F(x)$ . Te współczynniki będą później wykorzystywane jako punkt odniesienia do oceny jakości uzyskanej aproksymacji.

Idealne wartości funkcji  $F(x)$  obliczono na podstawie zależności:

$$F(x_i) = \sum_{j=1}^m a_j \phi_j(x_i),$$

a następnie dodano do nich losowe zaburzenia  $\delta y_i$ , generowane zgodnie z rozkładem normalnym o średniej 0 i odchyleniu standardowym  $\sigma$ . Otrzymane wartości  $y_i$  opisano jako:

$$y_i = F(x_i) + \delta y_i.$$

Celem zadania jest odzyskanie współczynników  $a_j$  na podstawie wygenerowanych par  $(x_i, y_i)$ . W tym celu zastosowano metodę najmniejszych kwadratów, która minimalizuje funkcję błędu:

$$E(a_1, \dots, a_m) = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m a_j \phi_j(x_i) \right)^2.$$

### 3 Metoda najmniejszych kwadratów i dekompozycja SVD

#### 3.1 Metoda najmniejszych kwadratów

Metoda najmniejszych kwadratów (ang. *Least Squares Method*) jest klasycznym podejściem do dopasowania modelu do danych w taki sposób, aby minimalizować sumę kwadratów błędów. W przypadku zadania aproksymacji, chcemy znaleźć współczynniki  $a_j$  funkcji  $F(x)$ , które minimalizują funkcję błędu:

$$E(a_1, \dots, a_m) = \sum_{i=1}^n \left( y_i - \sum_{j=1}^m a_j \phi_j(x_i) \right)^2.$$

Aby rozwiązać to zadanie, można zapisać problem w formie macierzowej. Niech:

$$\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}, \quad \mathbf{A} = \begin{bmatrix} \phi_1(x_1) & \phi_2(x_1) & \cdots & \phi_m(x_1) \\ \phi_1(x_2) & \phi_2(x_2) & \cdots & \phi_m(x_2) \\ \vdots & \vdots & \ddots & \vdots \\ \phi_1(x_n) & \phi_2(x_n) & \cdots & \phi_m(x_n) \end{bmatrix}, \quad \mathbf{a} = \begin{bmatrix} a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix}.$$

Wówczas problem minimalizacji można zapisać jako:

$$E(\mathbf{a}) = \|\mathbf{A}\mathbf{a} - \mathbf{y}\|^2.$$

Optymalne współczynniki  $\mathbf{a}$  spełniają układ równań normalnych:

$$\mathbf{A}^T \mathbf{A} \mathbf{a} = \mathbf{A}^T \mathbf{y}.$$

### 3.2 Dekompozycja SVD

W praktyce, szczególnie gdy macierz  $\mathbf{A}$  jest źle uwarunkowana lub niekwadratowa, układ równań normalnych może prowadzić do błędnych wyników. W takich przypadkach stosuje się dekompozycję SVD (ang. *Singular Value Decomposition*), która zapewnia bardziej stabilne rozwiązanie.

Dekompozycja SVD rozkłada macierz  $\mathbf{A}$  na iloczyn trzech macierzy:

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T,$$

gdzie:

- $\mathbf{U}$  jest macierzą ortogonalną ( $\mathbf{U}^T\mathbf{U} = \mathbf{I}$ ),
- $\mathbf{\Sigma}$  jest macierzą diagonalną zawierającą wartości singularne  $\sigma_i$ ,
- $\mathbf{V}$  jest macierzą ortogonalną ( $\mathbf{V}^T\mathbf{V} = \mathbf{I}$ ).

Rozwiązanie problemu najmniejszych kwadratów za pomocą SVD wyraża się jako:

$$\mathbf{a} = \mathbf{V}\mathbf{\Sigma}^+\mathbf{U}^T\mathbf{y},$$

gdzie  $\mathbf{\Sigma}^+$  jest macierzą pseudoodwrotną do  $\mathbf{\Sigma}$ , otrzymywana poprzez odwrócenie jej niezerowych elementów diagonalnych.

### 3.3 Zalety zastosowania SVD

Zastosowanie dekompozycji SVD ma następujące zalety:

- Jest stabilne numerycznie, szczególnie w przypadku źle uwarunkowanych macierzy.
- Umożliwia łatwą identyfikację i eliminację najmniejszych wartości singularnych, co pomaga w redukcji efektów błędów zaokrągleń i szumów w danych.
- Daje rozwiązanie nawet w przypadku układów równań nadokreślonych (gdy  $n > m$ ) lub niedookreślonych (gdy  $n < m$ ).

Podsumowując, metoda najmniejszych kwadratów w połączeniu z dekompozycją SVD jest skutecznym narzędziem do aproksymacji danych w obecności szumów, zapewniając wysoką dokładność i stabilność obliczeń.

## 4 Wybrany wielomian uogólniony

W zadaniu zdecydowano się na użycie wielomianu uogólnionego z  $m = 6$  parametrami. Funkcje bazowe  $\phi_j(x)$  zostały dobrane w taki sposób, aby zachować różnorodność i złożoność zachowania funkcji w przedziale  $x \in (-1, 1)$ . Wybrane funkcje bazowe to:

$$\begin{aligned}
\phi_1(x) &= \sin(x \cdot e^x), \\
\phi_2(x) &= \cos(\log(x^2) \cdot \tanh(x)), \\
\phi_3(x) &= \exp(x^2 \cdot \sin(x^2)), \\
\phi_4(x) &= \sin(\cos(e^x)), \\
\phi_5(x) &= \cos\left(\frac{1}{1+|x|} \cdot e^x\right).
\end{aligned}$$

Współczynniki  $a_j$  zostały ustalone na następujące wartości:

$$a_1 = -0.5, \quad a_2 = 1.0, \quad a_3 = -0.5, \quad a_4 = 1.5, \quad a_5 = -0.5, \quad a_6 = -2.5.$$

Taki dobór współczynników został dokonany z zamiarem uzyskania ciekawego zachowania funkcji  $F(x)$  w zadanym przedziale. Wartości te pozwalają na generowanie danych charakteryzujących się dużą zmiennością i złożonymi zależnościami między wartościami  $x_i$  i  $y_i$ , co sprzyja dokładnemu sprawdzeniu skuteczności metody aproksymacji.

## Analiza funkcji bazowych

Wybrane funkcje bazowe są nieliniowe i wprowadzają różne cechy do modelu:

- $\phi_1(x) = \sin(x \cdot e^x)$  – generuje oscylacje, których amplituda rośnie wykładniczo.
- $\phi_2(x) = \cos(\log(x^2) \cdot \tanh(x))$  – wprowadza funkcje logarytmiczną w połączeniu z hiperboliczną.
- $\phi_3(x) = \exp(x^2 \cdot \sin(x^2))$  – zwiększa nieliniowość, wprowadzając funkcje wykładniczą skomponowaną z sinusoidą.
- $\phi_4(x) = \sin(\cos(e^x))$  – łączy funkcje trygonometryczne i wykładnicze.
- $\phi_5(x) = \cos\left(\frac{1}{1+|x|} \cdot e^x\right)$  – wprowadza funkcje wymierną, wzmacniając różnorodność.

Przyjęte funkcje i współczynniki mają na celu stworzenie ciekawego i wymagającego przypadku testowego, umożliwiającego dokładne sprawdzenie skuteczności metody najmniejszych kwadratów.

## 5 Wyniki dla różnych poziomów zaburzeń i liczby punktów

Wyniki aproksymacji zostały przeanalizowane dla różnych wartości odchylenia standardowego zaburzeń ( $\sigma$ ) oraz liczby punktów ( $N$ ). Poniżej przedstawiono wyznaczone współczynniki aproksymacji oraz wizualizacje funkcji.

### 5.1 Zaburzenie $\sigma = 0.1$

- Liczba punktów  $N = 10$ :

$$a = \{-0.587054, 1.02244, -0.482905, 1.4313, -0.618955, -2.39197\}.$$

- Liczba punktów  $N = 25$ :

$$a = \{-0.524002, 0.986735, -0.503234, 1.41216, -0.573481, -2.30794\}.$$

- Liczba punktów  $N = 70$ :

$$a = \{-0.419742, 1.21583, -0.565099, 1.43645, -0.376014, -2.67486\}.$$

- Liczba punktów  $N = 100$ :

$$a = \{-0.502208, 0.75287, -0.44646, 1.39498, -0.503609, -2.08698\}.$$

### 5.2 Zaburzenie $\sigma = 0.5$

- Liczba punktów  $N = 10$ :

$$a = \{0.171659, 4.36458, -1.35513, 4.16532, 0.0422072, -10.9065\}.$$

- Liczba punktów  $N = 25$ :

$$a = \{0.304039, 1.4799, -0.546012, 3.10255, 0.527213, -6.82663\}.$$

- Liczba punktów  $N = 70$ :

$$a = \{-0.564114, 0.507845, -0.365722, 1.37339, -0.611113, -1.74082\}.$$

- Liczba punktów  $N = 100$ :

$$a = \{-1.32073, 0.636297, -0.518278, 0.812597, -1.23661, -0.061968\}.$$

### 5.3 Zaburzenie $\sigma = 1.5$

- Liczba punktów  $N = 10$ :

$$a = \{0.515271, 0.0198563, 0.685153, 0.663381, 1.8435, -4.97215\}.$$

- Liczba punktów  $N = 25$ :

$$a = \{-2.11554, -1.55792, 0.00921909, 0.108171, -2.39021, 3.8261\}.$$

- Liczba punktów  $N = 70$ :


$$a = \{-3.1152, 4.56663, -2.18418, 1.46649, -2.95888, -1.5162\}.$$

- Liczba punktów  $N = 100$ :


$$a = \{-1.62989, -0.617211, -0.801978, -1.74618, -1.79915, 7.46054\}.$$

## 5.4 Wizualizacja wyników


Dla wybranych parametrów  $\sigma$  i  $N$  przygotowano wykresy aproksymowanych funkcji:



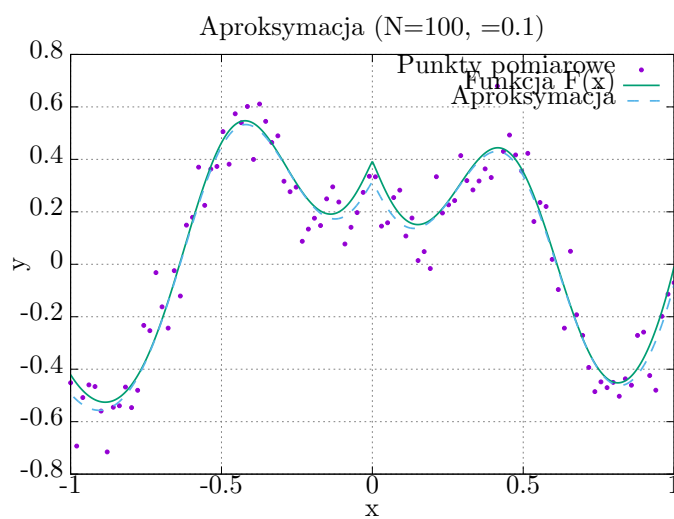
Wykres funkcji  $F(x)$  dla  $\sigma = 0.1$  i  $N = 10$ .




Wykres funkcji  $F(x)$  dla  $\sigma = 0.1$  i  $N = 25$ .




Wykres funkcji  $F(x)$  dla  $\sigma = 0.1$  i  $N = 70$ .



Wykres funkcji  $F(x)$  dla  $\sigma = 0.1$  i  $N = 100$ .


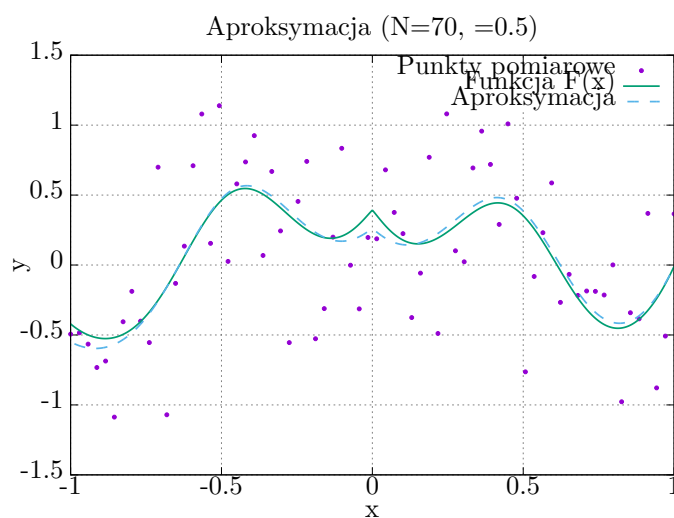


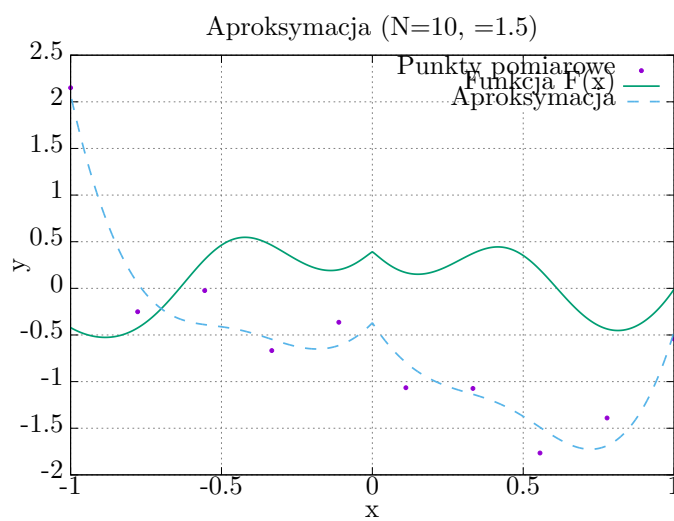
Wykres funkcji  $F(x)$  dla  $\sigma = 0.5$  i  $N = 10$ .




Wykres funkcji  $F(x)$  dla  $\sigma = 0.5$  i  $N = 25$ .









Wykres funkcji  $F(x)$  dla  $\sigma = 1.5$  i  $N = 10$ .



Wykres funkcji  $F(x)$  dla  $\sigma = 1.5$  i  $N = 25$ .



Wykres funkcji  $F(x)$  dla  $\sigma = 1.5$  i  $N = 70$ .



Wykres funkcji  $F(x)$  dla  $\sigma = 1.5$  i  $N = 100$ .

## 6 Dyskusja

Wyniki aproksymacji funkcji  $F(x)$  w obecności różnych poziomów zaburzeń ( $\sigma$ ) oraz liczby punktów ( $N$ ) pozwalają na wyciągnięcie kilku istotnych wniosków dotyczących stabilności i dokładności metody najmniejszych kwadratów.

## 6.1 Wpływ liczby punktów ( $N$ )

Wraz ze wzrostem liczby punktów ( $N$ ), wyniki aproksymacji stają się bardziej stabilne i dokładniejsze. Dla mniejszych wartości  $N$ , takich jak  $N = 10$ , współczynniki  $a_j$  znacząco odbiegają od wartości oryginalnych. Wynika to z ograniczonej ilości informacji dostarczanej przez dane, co prowadzi do niestabilności w procesie aproksymacji. Z kolei dla większych wartości  $N$ , takich jak  $N = 70$  lub  $N = 100$ , wyznaczone współczynniki są bliższe oryginalnym wartościom, nawet przy wyższym poziomie zaburzeń ( $\sigma = 0.5$ ).

## 6.2 Wpływ poziomu zaburzeń ( $\sigma$ )

Zwiększenie poziomu zaburzeń ( $\sigma$ ) prowadzi do większych odchyłeń współczynników aproksymacji od ich rzeczywistych wartości. Dla  $\sigma = 0.1$ , uzyskane współczynniki są stosunkowo bliskie pierwotnym wartościom nawet przy niewielkiej liczbie punktów  $N$ . Natomiast dla  $\sigma = 1.5$ , nawet przy  $N = 100$ , aproksymacja jest znacząco zaburzona, co wskazuje na ograniczenia metody najmniejszych kwadratów w obecności dużego szumu.

## 6.3 Porównanie wyników

Analizując wyniki dla różnych kombinacji  $N$  i  $\sigma$ , można zauważyć, że metoda najmniejszych kwadratów działa najlepiej przy umiarkowanym poziomie szumu ( $\sigma \leq 0.5$ ) oraz odpowiednio dużej liczbie punktów ( $N \geq 70$ ). W takich przypadkach uzyskane współczynniki  $a_j$  są zbliżone do rzeczywistych wartości, a wykresy funkcji dobrze odwzorowują oryginalną funkcję  $F(x)$ .

Z kolei przy dużych zaburzeniach ( $\sigma = 1.5$ ) metoda staje się mniej efektywna, co jest szczególnie widoczne dla mniejszych  $N$ . W takich sytuacjach konieczne może być zastosowanie bardziej zaawansowanych metod aproksymacji, takich jak regularizacja (np. metoda grzbietowa) lub metody odpornościowe (ang. *robust methods*), które lepiej radzą sobie z szumem.

## 6.4 Ograniczenia i potencjalne ulepszenia

Metoda najmniejszych kwadratów, mimo swojej prostoty i efektywności w wielu przypadkach, ma ograniczenia w sytuacjach, gdy dane są mocno zaburzone. Wyniki pokazują, że dla większych wartości  $\sigma$ , szczególnie przy niewielkim  $N$ , uzyskane współczynniki mogą być niestabilne i znacznie odbiegać od rzeczywistych wartości. W takich sytuacjach potencjalne ulepszenia mogłyby obejmować:

- Zastosowanie regularizacji, aby zmniejszyć wpływ szumu na proces aproksymacji.
- Wykorzystanie metod odpornościowych, które są mniej wrażliwe na wartości odstające.

- Analize właściwego doboru funkcji bazowych  $\phi_j(x)$ , aby lepiej dostosować je do charakteru danych.

## 6.5 Wnioski końcowe

Przeprowadzona analiza pokazuje, że metoda najmniejszych kwadratów jest skuteczna przy niskim poziomie szumu i wystarczająco dużej liczbie punktów. Jednak w przypadku większych zaburzeń konieczne jest rozważenie bardziej zaawansowanych metod, które zapewnia lepszą odporność na szum i większą stabilność wyników.